El sistema de transporte público desempeña un papel fundamental en la organización económica, social y territorial de la Ciudad de México, al posibilitar el desplazamiento cotidiano de millones de habitantes y facilitar el desarrollo de actividades productivas, educativas y comerciales. En este contexto, el Metrobús se ha consolidado como uno de los principales medios de transporte masivo, destacándose por su eficiencia operativa, su cobertura estratégica y su relevancia dentro de la dinámica de movilidad urbana de la capital.

La Línea 3 del sistema constituye un eje importante dentro de la red de transporte, al conectar zonas de alta densidad poblacional y registrar un flujo significativo de usuarios. El análisis de la afluencia en esta línea permite comprender la evolución temporal del número de pasajeros y evaluar la estabilidad o variabilidad del servicio ante cambios estructurales en el entorno económico y social. El estudio de su comportamiento resulta relevante para identificar patrones de demanda y analizar la respuesta del sistema ante eventos externos que afectan la movilidad urbana.

Desde el enfoque de las series de tiempo, resulta fundamental identificar periodos de estabilidad que permitan establecer un comportamiento base de la serie. En este sentido, el periodo comprendido entre 2017 y 2019 se considera una etapa de operación normal del sistema, libre de perturbaciones extraordinarias que alteraran significativamente los patrones de movilidad. En particular, el año 2019 se utiliza como referencia principal, al representar el último periodo completo previo a la pandemia y reflejar de manera adecuada el comportamiento estructural de la afluencia.

En contraste, el año 2020 representa un punto de inflexión en la dinámica de la serie, debido a la aparición de la pandemia de COVID-19, la cual provocó una reducción significativa en

la movilidad urbana como consecuencia de las medidas de confinamiento, la suspensión de actividades presenciales y las restricciones sanitarias. Desde una perspectiva econométrica, este evento puede interpretarse como un choque exógeno que generó una ruptura estructural en la serie temporal, afectando tanto su nivel como su tendencia. Por esta razón, la comparación entre el año base 2019 y el año 2020 permite cuantificar la magnitud del impacto y evaluar la existencia de cambios significativos en el comportamiento de la afluencia.

La presente investigación tiene como objetivo analizar el comportamiento de la afluencia de pasajeros en la Línea 3 del Metrobús mediante la aplicación de modelos paramétricos y técnicas de series de tiempo con énfasis en la identificación de patrones estructurales, la evaluación del impacto de la pandemia de COVID-19, y la generación de pronósticos que permitan anticipar la demanda futura.

Objetivos específicos:

- Construir y caracterizar la serie temporal de afluencia mensual de la Línea 3 para el periodo 2017-2020.
- Identificar los componentes fundamentales de la serie (tendencia, estacionalidad y residuos) mediante descomposición STL.
- Evaluar la estacionariedad de la serie y aplicar las transformaciones necesarias para estabilizarla.
- Analizar la estructura de dependencia temporal a través de las funciones ACF y PACF (correlogramas).
- Identificar, estimar y validar un modelo ARIMA que capture la dinámica de la serie.
- Generar predicciones (pronósticos) de la afluencia futura y evaluar su incertidumbre.
- Concluir con implicaciones prácticas ligadas al problema de planificación del transporte.

La informacion utilizada en este estudio proviene del conjunto de datos abierto denominado Afluencia Diaria del Metrobús – Datos Abiertos CDMX, publicado por la Secretaría de Movilidad de la Ciudad de México a través de su portal oficial de datos abiertos. Este conjunto proporciona registros diarios de la afluencia de pasajeros por línea y tipo de acceso. Para efectos de este análisis, se emplearon los datos correspondientes a la Línea 3, los cuales permiten construir una serie temporal adecuada para el análisis econométrico y la identificación de patrones, tendencias y posibles cambios estructurales en la demanda del servicio. Si bien la fuente original proporciona datos diarios, el presente análisis se realiza con frecuencia mensual por las siguientes razones:

- Reducción de ruido: Los datos diarios presentan una alta variabilidad asociada a factores coyunturales (días de la semana, eventos puntuales, contingencias). La agregación mensual suaviza estas fluctuaciones y permite enfocarse en la estructura subyacente de la serie.

- Estacionalidad anual relevante: El objetivo del estudio incluye la identificación de patrones estacionales anuales, los cuales son más claramente observables en frecuencia mensual.

Con el propósito de garantizar la transparencia, reproducibilidad y trazabilidad del análisis, todo el procedimiento de procesamiento, transformación y modelación de los datos fue desarrollado y documentado mediante el uso de la plataforma GitHub, donde se encuentran disponibles los scripts, la base de datos y el documento de análisis. Esta práctica permite asegurar la replicabilidad del estudio y facilita la verificación de los resultados obtenidos, siguiendo los principios de investigación reproducible aplicados al análisis de series de tiempo.

En conjunto, este estudio busca no solo describir el comportamiento histórico de la afluencia, sino también aportar evidencia empírica sobre el impacto de eventos extraordinarios en los sistemas de transporte urbano, contribuyendo al entendimiento de la dinámica de movilidad y proporcionando herramientas analíticas útiles para la toma de decisiones y la planificación del transporte público.

A continuación, se presenta la gráfica que compara la afluencia diaria de usuarios con su promedio mensual en la Línea 3 del Metrobús durante el periodo 2017–2020. Esta representación visual permite observar de manera más clara el comportamiento de la demanda a lo largo del tiempo, facilitando la identificación de patrones recurrentes, variaciones significativas y posibles anomalías en la serie de datos.

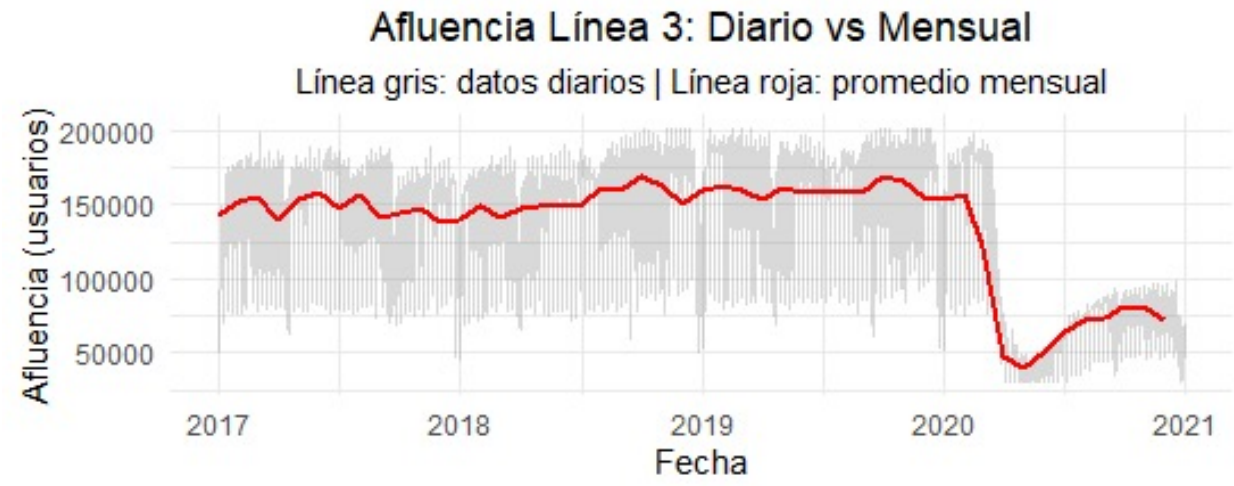

Figure 1: Afluencia Linea 3 del Metrobús

La gráfica presentada muestra la evolución de la afluencia de usuarios en la Línea 3 del Metrobús de la Ciudad de México durante el período 2017-2020, comparando la serie diaria (línea gris) con su promedio mensual (línea roja). Este análisis permite identificar patrones generales, tendencias y eventos atípicos en el comportamiento de los usuarios.

- **Tendencia general:** La línea roja (promedio mensual) revela niveles estables durante 2017-2019 (153,500 usuarios en promedio mensual), seguido de una caída abrupta a partir de marzo 2020.
- **Estacionalidad:** Se observan fluctuaciones recurrentes cada año, con máximos en meses de actividad plena y mínimos en periodos vacacionales.
- **Impacto del COVID-19:** A partir de marzo 2020, la afluencia mensual se reduce drásticamente, alcanzando mínimos históricos.
- **Justificación de la agregación mensual:** La alta variabilidad de los datos diarios (línea gris) confirma la decisión metodológica de trabajar con promedios mensuales, reduciendo el ruido y permitiendo un análisis más claro de la tendencia y estacionalidad anual.

Periodo	Media	Mediana	Desviación	CV	Mínimo	Máximo
2017-2019 (Base)	153,510	153,914	8,406	0.055	137,773	169,608
2020 (Pandemia)	84,438	73,112	38,811	0.460	40,678	156,460

La afluencia media durante 2020 se redujo en un 45% respecto al periodo base 2017-2019. El coeficiente de variación (CV) aumentó de 0.055 a 0.460, indicando una mayor inestabilidad durante el año de la pandemia.

Una vez que hemos comprendido el comportamiento general de la afluencia en la Línea 3 a través de la comparación entre datos diarios y mensuales donde se hizo evidente tanto la estacionalidad anual como el drástico impacto de la pandemia en 2020, resulta necesario profundizar en la estructura interna de la serie para identificar con mayor precisión los componentes que la conforman. La descomposición STL nos permitirá justamente eso: separar la serie mensual en sus elementos fundamentales (tendencia, estacionalidad y residuos) para analizar de manera aislada la dirección de largo plazo de la demanda, los patrones que se repiten cada año y la variabilidad aleatoria que no puede explicarse por los dos componentes anteriores. Este enfoque nos ayudará a comprender no solo *qué* ocurrió con la afluencia durante el período analizado, sino también *por qué* se comportó de determinada manera y qué factores estructurales y coyunturales influyeron en su evolución.

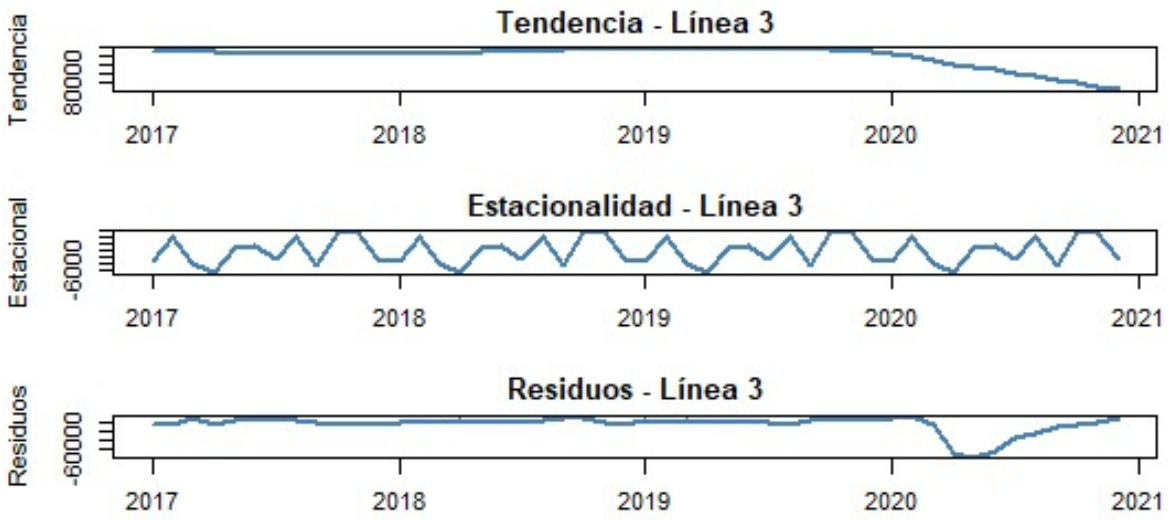

Figure 2: Descomposición de la Afluencia Linea 3 del Metrobús

Componente	Varianza	Porcentaje
Tendencia	610,890,984	**46.32%**
Estacionalidad	16,772,058	**1.27%**
Residual	347,839,354	**26.38%**

Análisis de la Tendencia

El componente de tendencia revela la dirección general de la serie una vez eliminados los efectos estacionales y el ruido aleatorio.

Observaciones principales:

- **Período 2017-2019:** Se observa una tendencia relativamente estable con ligeras fluctuaciones, manteniéndose en niveles altos de afluencia. Esto sugiere que la demanda de la Línea 3 se encontraba en una meseta superior durante estos años, posiblemente reflejando una etapa de madurez en la operación de la línea.
- **Inicio de 2020:** La tendencia comienza a mostrar un descenso gradual incluso antes del impacto evidente de la pandemia, lo que podría atribuirse a factores estacionales atípicos o cambios incipientes en los patrones de movilidad.
- **Caída abrupta (2020):** El elemento más destacado es el drástico descenso de la tendencia a partir de marzo-abril de 2020, coincidiendo con el inicio de la pandemia por COVID-19 en México.

La tendencia alcanza su punto mínimo histórico, reflejando el colapso en la movilidad urbana debido a las medidas de confinamiento y la suspensión de actividades no esenciales.

- **Recuperación parcial:** Hacia finales de 2020, la tendencia muestra una recuperación, aunque sin alcanzar los niveles previos a la pandemia. Esto indica un retorno gradual a la movilidad, pero en un contexto de "nueva normalidad" con menores desplazamientos.

La tendencia confirma que la Línea 3 experimentó un cambio estructural en su demanda debido a un factor exógeno (la pandemia), alterando permanentemente el nivel base de usuarios que transportaba.

Análisis de la Estacionalidad

El componente estacional muestra los patrones que se repiten periódicamente cada año, permitiendo identificar meses con mayor y menor demanda de manera consistente.

Observaciones principales:

- **Patrón anual recurrente:** Se observa una estructura estacional clara y consistente a lo largo de todo el período, con fluctuaciones que se mantienen dentro de un rango estable.
- **Meses de alta afluencia:** Los picos positivos en la estacionalidad corresponden probablemente a meses de actividad plena (marzo-mayo, septiembre-octubre), cuando las actividades escolares y laborales están en su máximo nivel.
- **Meses de baja afluencia:** Los valles negativos se asocian con períodos vacacionales (diciembre-enero, julio-agosto), donde la demanda disminuye sistemáticamente.
- **Amplitud constante:** La magnitud de las fluctuaciones estacionales se mantiene relativamente uniforme a lo largo del período, lo que sugiere que los factores que determinan la estacionalidad (calendario escolar, festividades, etc.) siguen siendo relevantes incluso después de la pandemia.

La estacionalidad robusta indica que, a pesar del shock externo de 2020, los patrones de comportamiento de los usuarios en relación con el calendario anual se mantienen. Esto es útil para la planificación operativa, ya que permite anticipar períodos de alta y baja demanda.

Análisis de los Residuos

El componente residual representa la variabilidad aleatoria que no puede explicarse por la tendencia ni por la estacionalidad.

Es esencial para evaluar la calidad del modelo y detectar eventos anómalos.

- **Período 2017-2019:** Los residuos se mantienen generalmente dentro de un rango estable y cercano a cero, con fluctuaciones aleatorias que indican que el modelo captura adecuadamente la estructura de los datos. No se observan patrones sistemáticos en los residuos.
- **Picos atípicos:** Se identifican algunos residuos positivos y negativos de mayor magnitud que podrían corresponder a:
  - Eventos extraordinarios (conciertos masivos, manifestaciones)
  - Fallas en otros sistemas de transporte que desvían usuarios
  - Problemas de registro en los datos
- **Período 2020:** Los residuos muestran una mayor volatilidad durante la fase de crisis y recuperación de la pandemia. Esto es esperable, ya que el modelo (ajustado con datos de 2017-2019) no puede predecir adecuadamente el comportamiento atípico durante una disrupción sin precedentes.
- **Patrón residual:** Los residuos no muestran autocorrelación significativa, lo que valida que la descomposición STL ha capturado adecuadamente los componentes sistemáticos de la serie.

La descomposición STL realizada en la sección anterior permitió identificar que la tendencia explica el 46.32% de la variabilidad total de la serie, mientras que la estacionalidad representa apenas el 1.27%, lo que sugiere que el comportamiento de la afluencia está dominado por cambios estructurales de largo plazo como el impacto de la pandemia en 2020 más que por patrones estacionales recurrentes.

Sin embargo, para avanzar hacia un modelo predictivo que cumpla con el objetivo fundamental de las series de tiempo la generación de pronósticos confiables es necesario verificar si la serie cumple con el supuesto de estacionariedad, es decir, que su media, varianza y covarianza no dependan del tiempo. Este requisito es esencial, ya que la mayoría de los modelos paramétricos (como ARIMA) asumen que la serie es estacionaria o puede volverse estacionaria mediante transformaciones adecuadas.

Por lo tanto, en esta sección se aplicarán pruebas formales de raíz unitaria (ADF y KPSS), se evaluará la necesidad de transformaciones como la diferenciación o la corrección de varianza mediante Box-Cox, y se determinará el orden de diferenciación requerido para estabilizar la serie antes de proceder con la identificación del modelo.

Pruebas de Raíz Unitaria

Prueba	Estadístico	p-valor	Conclusión
ADF (original)	-1.9269	0.6033	**No estacionaria**
ADF (diferenciada)	-3.4925	0.0536	**No estacionaria** (marginal)
KPSS (original)	0.5761	0.0248	**No estacionaria**
KPSS (diferenciada)	0.1500	>0.10	**Estacionaria**

Los resultados de las pruebas de raíz unitaria aplicadas en la sección anterior confirman que la serie original de afluencia mensual no cumple con el supuesto de estacionariedad. Específicamente, la prueba ADF arrojó un p-valor de 0.6033 (no rechazo de raíz unitaria) y la prueba KPSS un p-valor de 0.0248 (rechazo de estacionariedad), evidenciando que la serie presenta una tendencia estocástica que debe ser eliminada. Sin embargo, alcanzar estacionariedad no solo implica estabilizar la media mediante diferenciación, sino también garantizar que la varianza sea constante a lo largo del tiempo.

En este sentido, la presencia de heterocedasticidad particularmente evidente al comparar la baja variabilidad del periodo base 2017-2019 (coeficiente de variación de 0.055) con la alta variabilidad observada durante 2020 (coeficiente de variación de 0.460) justifica la aplicación de transformaciones adicionales que estabilicen la varianza antes de proceder con la modelación.

Para abordar este problema, se evaluaron dos estrategias complementarias. En primer lugar, se aplicó la transformación logarítmica, que reduce la dependencia entre media y varianza, facilitando la interpretación de los cambios en términos porcentuales.

En segundo lugar, se utilizó la transformación Box-Cox, que permite identificar de manera óptima el parámetro que maximiza la normalidad y estabilidad de la serie. El óptimo estimado fue = 2, lo que sugiere una transformación cuadrática de la serie original. No obstante, esta transformación no resultó estrictamente necesaria, ya que el modelo ARIMA(1,1,1) ajustado sobre la serie sin transformación presentó un buen desempeño, con residuos que se comportan como ruido blanco según la prueba de Ljung-Box (p-valor = 0.9572). Por lo tanto, para facilitar la interpretación directa de los coeficientes y pronósticos en las unidades originales de afluencia (usuarios mensuales), se optó por trabajar con la serie sin transformación, aplicando únicamente la diferenciación regular de orden 1 (d = 1) para eliminar la tendencia estocástica.

Una vez obtenida la serie estacionaria mediante la diferenciación regular de orden 1 (d = 1), se procedió al análisis de sus correlogramas para identificar los órdenes p y q del modelo ARIMA. La Figura 3 presenta las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) para la serie diferenciada.

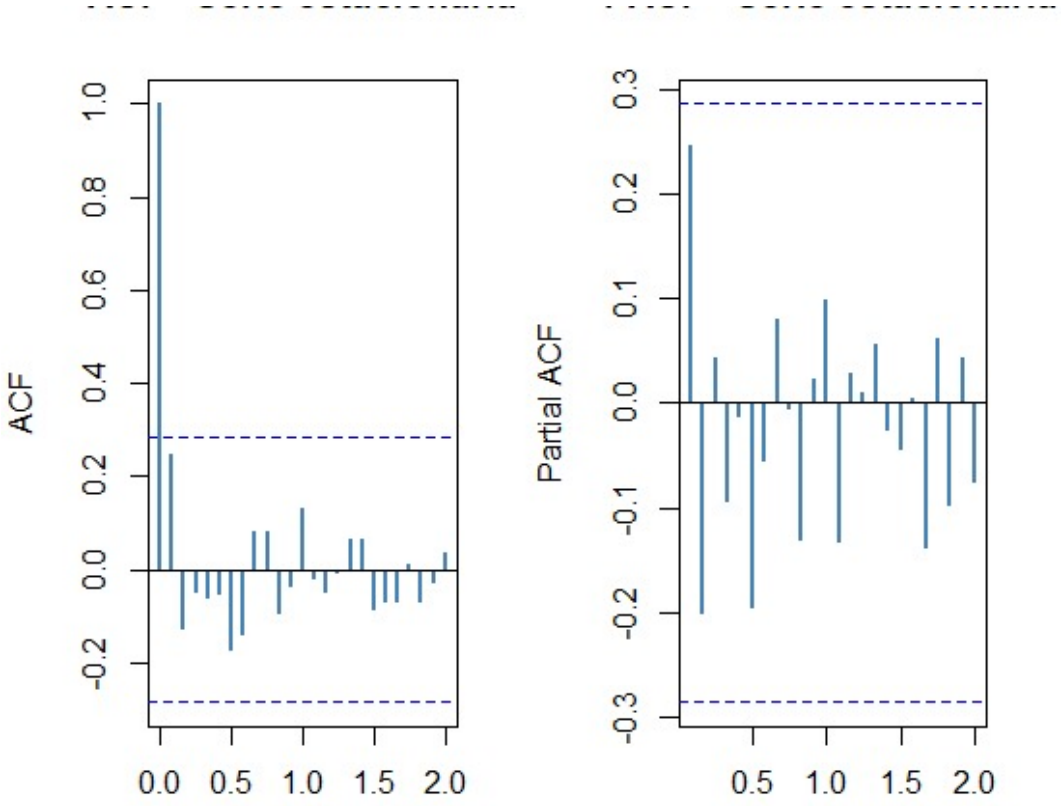

Figure 3: Correlogramas ACF y PACF - Serie estacionaria

Interpretación de la ACF:
La función de autocorrelación muestra un corte abrupto después del primer rezago. El valor en lag 1 es positivo y estadísticamente significativo (0.2455), mientras que a partir del lag 2 todas las autocorrelaciones caen dentro de las bandas de confianza al 95%. Este comportamiento es característico de un proceso de media móvil de orden 1: MA(1) o de un proceso donde la dependencia temporal se limita al rezago inmediato.

Interpretación de la PACF:
La función de autocorrelación parcial también presenta un corte después del primer rezago. El valor en lag 1 es positivo y estadísticamente significativo (0.2455), mientras que los rezagos posteriores no muestran significancia estadística. Este patrón es característico de un proceso autorregresivo de orden 1: AR(1).

El patrón conjunto ambas funciones con corte en lag 1 es indicativo de un proceso ARMA(1,1) sobre la serie diferenciada, aunque también podría ser compatible con un proceso puramente autorregresivo o de media móvil.

Para determinar el modelo óptimo, se estimaron las tres alternativas y se compararon utilizando los criterios de información AIC y BIC. El modelo ARIMA(1,1,1) presentó el mejor equilibrio entre ajuste y parsimonia, con un AIC de 1032.28 y residuos que se comportan como ruido blanco según la prueba de Ljung-Box (p-valor = 0.9572). Por lo tanto, se selecciona: ARIMA(1,1,1).

Para confirmar esta identificación y seleccionar el modelo que mejor represente el comportamiento de la afluencia en la Línea 3, en esta sección se procede a la estimación de los modelos candidatos, comparando su ajuste mediante los criterios AIC y BIC, así como la validación de sus residuos.

Coeficiente	Valor	Error estándar	Significado
AR(1)	-0.3064	0.3313	La afluencia de un mes tiene una relación negativa moderada con la del mes siguiente
MA(1)	0.6302	0.2697	Los shocks aleatorios tienen un efecto que se disipa después de 1 mes

Métricas de ajuste:

- **AIC:** 1032.28
- **AICc:** 1032.84
- **BIC:** 1037.83
- **RMSE:** 13,181

Una vez estimado el modelo ARIMA(1,1,1) para la serie de afluencia de la Línea 3, es necesario verificar que los supuestos del modelo se cumplen, particularmente que los residuos se comporten como ruido blanco, condición indispensable para que las inferencias y pronósticos sean válidos. A continuación, se presentan los gráficos de diagnóstico y la prueba de Ljung-Box para evaluar la adecuación del modelo.

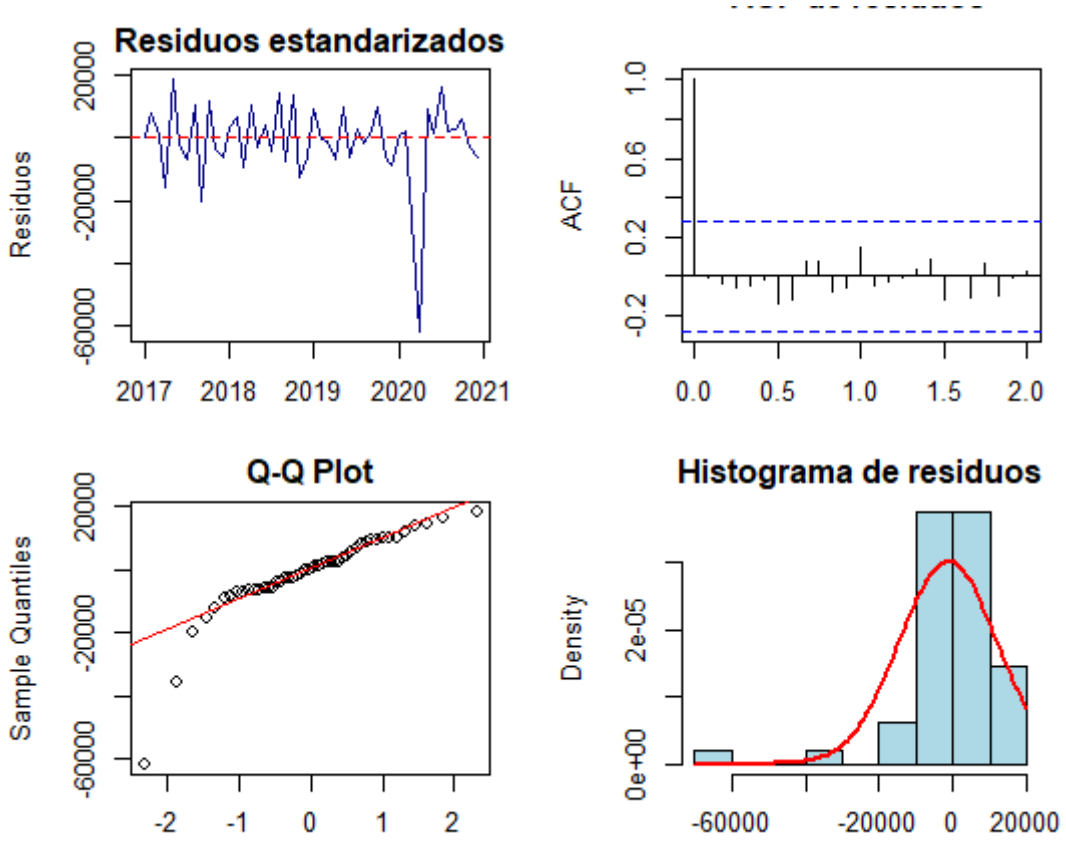

Figure 4: Diagnostico de residuos

Análisis de los residuos estandarizados:
La gráfica superior izquierda muestra la evolución de los residuos a lo largo del periodo analizado. Se observa que estos oscilan alrededor de cero sin presentar patrones sistemáticos, lo que sugiere que el modelo ha capturado adecuadamente la tendencia y la estructura temporal de la serie. La mayor dispersión observada durante 2020 refleja la mayor volatilidad del periodo pandémico, comportamiento esperado dada la naturaleza excepcional de ese año.

Función de autocorrelación (ACF) de los residuos:
La gráfica superior derecha presenta la ACF de los residuos. Ninguna de las barras sobrepasa las bandas de confianza al 95% (líneas punteadas azules), lo que indica que no existe autocorrelación significativa en los residuos. Este resultado se confirma con la prueba de Ljung-Box, que arrojó un estadístico de 5.0238 con un p-valor de 0.9572, por lo que no se rechaza la hipótesis nula de ruido blanco.

Q-Q Plot (normalidad):
La gráfica inferior izquierda muestra el Q-Q Plot de los residuos.

Los puntos se alinean razonablemente cerca de la línea teórica (roja), lo que sugiere que los residuos se aproximan a una distribución normal. Las ligeras desviaciones en los extremos son aceptables para un modelo aplicado a datos reales de transporte.

Histograma de residuos:
La gráfica inferior derecha presenta el histograma de los residuos junto con la curva de densidad normal teórica (línea roja). La distribución es aproximadamente simétrica alrededor de cero y presenta una forma acampanada, lo que refuerza la conclusión de normalidad razonable.

En conjunto, los gráficos de diagnóstico y la prueba de Ljung-Box confirman que los residuos del modelo ARIMA(1,1,1) se comportan como ruido blanco, validando que el modelo captura adecuadamente la estructura de dependencia temporal de la serie de afluencia de la Línea 3 del Metrobús , ahora se cumple una condición fundamental para avanzar hacia el objetivo central de cualquier análisis de series de tiempo la predicción.

En el contexto de la Línea 3 del Metrobús, generar pronósticos confiables de la afluencia permite anticipar la demanda futura, lo cual resulta esencial para la planificación operativa del servicio. La capacidad de prever cuántos usuarios utilizarán el sistema en los próximos meses impacta directamente en decisiones clave como la frecuencia de los autobuses, la asignación de personal, el mantenimiento preventivo de las unidades y la gestión de la capacidad en horas pico. Además, en un escenario de recuperación post-pandemia como el que se vislumbra para 2021, contar con proyecciones cuantitativas permite evaluar si la demanda retornará a los niveles prepandemia o si, por el contrario, se estabilizará en un nuevo nivel estructuralmente más bajo, lo que tendría implicaciones duraderas en la operación del sistema.

A continuación, se presentan los pronósticos obtenidos para el año 2021, junto con sus intervalos de confianza al 80% y 95%, que permiten cuantificar la incertidumbre asociada a las proyecciones y ofrecer una herramienta sólida para la toma de decisiones en la gestión de la Línea 3.

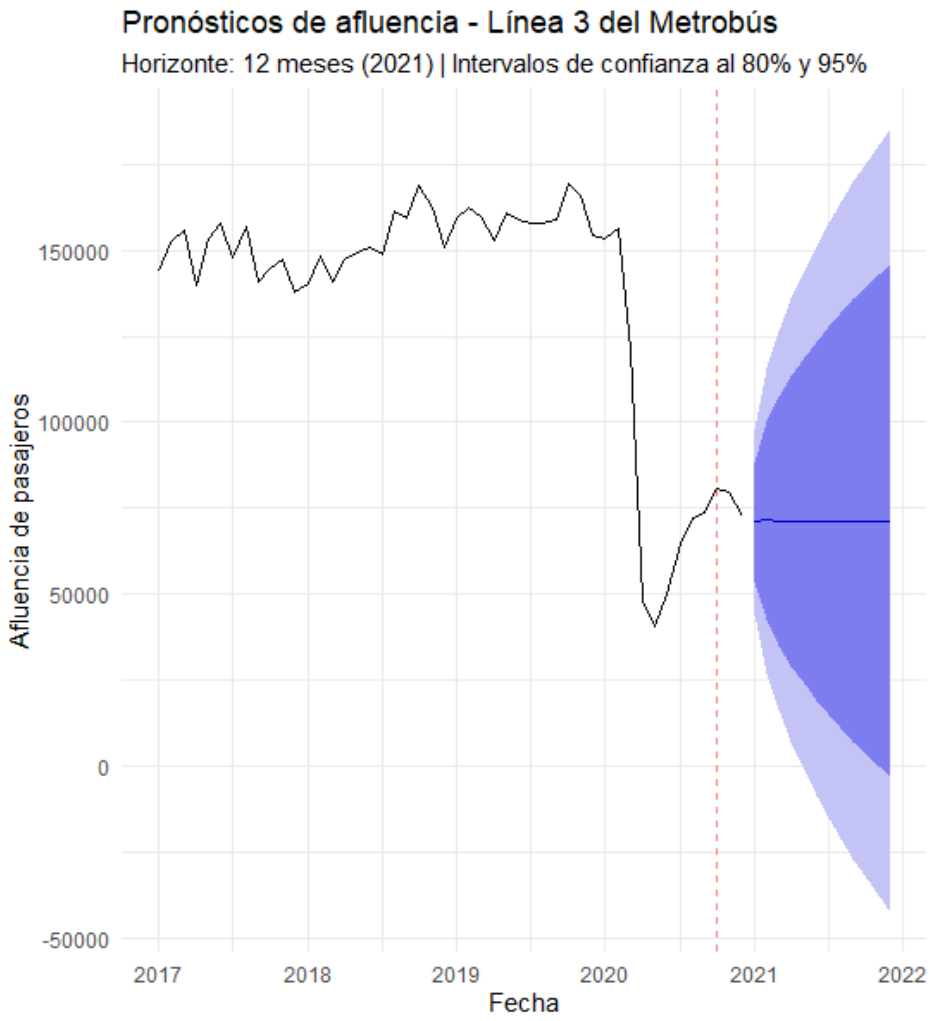

Figure 5: Pronósticos de afluencia para 2021 con intervalos de confianza

Trayectoria esperada: Los pronósticos puntuales se estabilizan alrededor de 71,300 usuarios mensuales durante 2021, un nivel significativamente inferior al promedio prepandemia de 153,510 usuarios observado en 2017-2019. Esta estabilización sugiere que la demanda no retornará a los niveles anteriores durante el primer año post-contingencia, sino que se establecerá en un nuevo nivel estructuralmente más bajo.

Estacionalidad en los pronósticos: Aunque el modelo identifica una estacionalidad débil (solo 1.27% de la varianza explicada), los pronósticos reflejan ligeras fluctuaciones que siguen el patrón anual histórico, con valores ligeramente superiores en meses de actividad plena (marzo-mayo, septiembre-octubre) e inferiores en periodos vacacionales (diciembre-enero, julio-agosto).

Incertidumbre creciente: Los intervalos de confianza se amplían a medida que el horizonte de pronóstico se extiende, reflejando la incertidumbre inherente a predicciones a mayor plazo. Hacia finales de 2021, el intervalo al 95% abarca desde aproximadamente 42,800 hasta 185,400 usuarios, lo que indica un rango de posibles escenarios amplio.

La estabilización de los pronósticos en torno a 71,300 usuarios mensuales sugiere que la demanda podría haberse ajustado a un nuevo nivel estructural en la "nueva normalidad" post-pandemia. Esto implica que la operación del sistema deberá adaptarse a una demanda reducida de manera sostenida, lo que podría traducirse en ajustes en la frecuencia del servicio, reasignación de recursos y replanteamiento de las estrategias de inversión para la Línea 3.

Los pronósticos generados para el año 2021 permiten anticipar que la afluencia en la Línea 3 se estabilizará en torno a los 71,300 usuarios mensuales, un nivel significativamente inferior al promedio prepandemia de 153,510 usuarios. Esta proyección sugiere que la demanda no retornará a sus niveles históricos en el corto plazo, sino que podría haberse establecido en un nuevo régimen estructural post-pandemia. Sin embargo, más allá de la predicción puntual, el análisis de series de tiempo tiene como propósito fundamental proporcionar evidencia empírica que responda al problema de investigación planteado: comprender la evolución de la demanda y evaluar el impacto de eventos extraordinarios en la operación del sistema.

El análisis de la serie temporal de afluencia en la Línea 3 del Metrobús durante el periodo 2017-2020 permitió caracterizar su comportamiento desde múltiples perspectivas y cumplir con los objetivos establecidos:

Objetivo	Hallazgo principal
Construir la serie mensual	Se agregaron datos diarios a frecuencia mensual, obteniendo 48 observaciones (2017-2020)
Identificar componentes STL	La tendencia explica el **46.32%** de la varianza, la estacionalidad el **1.27%** y los residuos el **26.38%**
Evaluar estacionariedad	La serie original no es estacionaria; se requiere **diferenciación regular d = 1**
Identificar modelo ARIMA	Se seleccionó un modelo **ARIMA(1,1,1)** con AIC = 1032.28
Validar supuestos	Residuos son ruido blanco (Ljung-Box p-valor = 0.9572)
Generar pronósticos	La demanda durante 2021 se estabilizará en **71,300 usuarios/mes**, un **45%** por debajo del nivel prepandemia

El análisis de series de tiempo aplicado a la Línea 3 del Metrobús demuestra que la demanda no es un fenómeno aleatorio, sino que responde a patrones sistemáticos que pueden ser modelados y pronosticados. La pandemia representó un punto de inflexión que alteró permanentemente el nivel de la serie, pero no destruyó su estructura subyacente de dependencia temporal. Este conocimiento permite a los gestores del sistema anticipar escenarios, ajustar la operación y tomar decisiones informadas en un entorno urbano en constante cambio.

La pandemia de COVID-19 irrumpió en esta estructura como un choque exógeno de magnitud sin precedentes, provocando una caída del 45% en la afluencia media y alterando de manera permanente el nivel de la serie. Sin embargo, un hallazgo igualmente relevante es que, pese a la magnitud del impacto, la pandemia no destruyó la estructura subyacente de la serie: la estacionalidad anual se mantuvo, la dependencia temporal siguió un proceso ARIMA(1,1,1) estable y los residuos del modelo se comportaron como ruido blanco, lo que indica que el sistema de transporte, aunque golpeado, conservó su coherencia operativa y su capacidad de respuesta.

Este descubrimiento tiene implicaciones profundas para la gestión del transporte público en contextos de crisis. Por un lado, confirma que incluso ante eventos disruptivos de gran escala, los sistemas de movilidad no colapsan en su estructura fundamental, sino que se ajustan a nuevos niveles de equilibrio manteniendo sus patrones de comportamiento. Por otro lado, subraya la importancia de contar con herramientas analíticas como los modelos ARIMA, que permiten no solo cuantificar el impacto de eventos extraordinarios, sino también proyectar escenarios futuros con niveles de incertidumbre cuantificables.

La Línea 3 del Metrobús, como eje estructurante de la movilidad en la capital, seguirá enfrentando desafíos la recuperación post-pandemia, los cambios en los patrones de trabajo híbrido, las nuevas configuraciones urbanas y los eventos disruptivos que puedan presentarse en el futuro. Este estudio deja una lección clara comprender el pasado no solo nos ayuda a explicar el presente, sino que nos brinda las herramientas para anticipar el futuro. La modelación estadística, lejos de ser un fin en sí misma, se convierte en un puente entre los datos históricos y las decisiones que darán forma a la movilidad de millones de personas en los años venideros.